§ 2. Решение уравнений с одной переменной.

Решение нелинейных уравнений с одной переменной (или систем таких уравнений) представляет собой одну из важных задач прикладного анализа. Эта проблема возникает в многочисленных и разнообразных разделах физики, механики, математики и техники.

Примером может служить проблема определения по заданным законам движения материальной точки того момента времени, когда эта частица попадает в определенную точку физического пространства.

В газовой динамике мы встречаемся с задачей определения состояния газа после прохождения по нему ударной волны и т.д.

В общем случае нелинейное уравнение можно записать в виде:

$$F(x) = 0, (2.1)$$

где функция F(x) определена и непрерывна на некотором отрезке [a,b].

Всякое число $\xi \in [a,b]$, обращающее функцию F(x) в нуль, т.е. такое, при котором $F(\xi) = 0$, называется корнем уравнения (2.1) или нулем функции F(x).

Число ξ называется *корнем k-й кратности*, если при $x=\xi$ вместе с функцией F(x) равны нулю ее производные до (k-1) порядка включительно – $F(\xi)=F'(\xi)=\ldots=F^{(k-1)}(\xi)=0$.

Однократный корень называется простым.

Два уравнения F(x) = 0 и G(x) = 0 называются *равносильными* (эквивалентными), если всякое решение одного из них является решением и для другого, т.е. множества решений этих уравнений совпадают, при условии обязательного совпадения областей определения этих функций.

Нелинейные уравнения с одним неизвестным подразделяются на *алгебраические* и *трансцендентные*.

Уравнение (2.1) называется *алгебраическим*, если выражение F(x) является алгебраической функцией.

Путем алгебраических преобразований из всякого алгебраического уравнения можно получить уравнение в канонической форме:

$$P_n(x) = a_n x^n + a_{n-1} x^{n-1} + \dots + a_1 x + a_0 = 0,$$
 (2.2)

где $a_0, \ a_1, \ \dots, \ a_n$ – коэффициенты уравнения, а x – неизвестное.

Показатель n называют степенью алгебраического уравнения.

Известно (из курса высшей алгебры), что всякое алгебраическое уравнение вида (2.2) имеет ровно n комплексных корней.

Существует ряд специальных численных методов решения уравнений (2.2): Берстоу-Хичкока, Берстоу-Ньютона, схема Горнера и т.д.

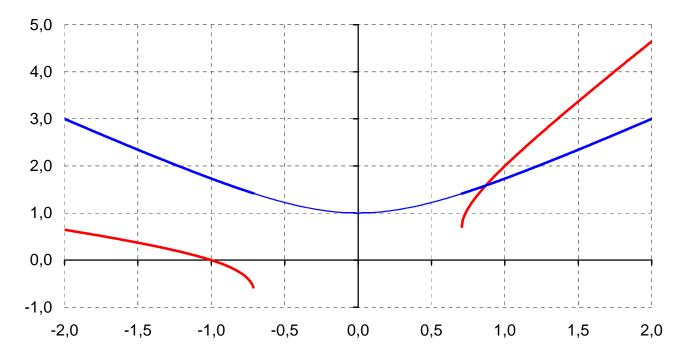
При приведении алгебраического уравнения (2.1) к канонической форме (2.2) будем иметь те же корни, что и для исходного уравнения.

Однако при этом могут появиться некоторые дополнительные корни.

Например, алгебраическое уравнение

$$\sqrt{2x^2 - 1} + x = \sqrt{2x^2 + 1}, \qquad (2.3)$$

с областью определения $x \in (-\infty, -\sqrt{0.5}] \cup [\sqrt{0.5}, \infty)$, имеет единственный корень – точка пересечения графиков функций $f_1(x) = \sqrt{2x^2 - 1} + x$ (график красного цвета с областью разрыва) и $f_2(x) = \sqrt{2x^2 + 1}$ (непрерывный график синего цвета):



Исходное уравнение (2.3), приведенное путем алгебраических преобразований к канонической форме:

$$7x^4 - 4 = 0$$
 или $x^4 - \lambda^4 = 0$, где $\lambda = \sqrt[4]{4/7}$,

уже будет иметь дополнительные корни, включая и комплексно сопряженные:

$$x^4 - \lambda^4 = (x^2 - \lambda^2)(x^2 + \lambda^2) = 0,$$
 $x_{1,2} = \pm \lambda$ и $x_{3,4} = \pm i \cdot \lambda$.

откуда

Очевидно, что искомым решением исходного нелинейного уравнения (2.3) будет единственная точка с абсциссой $x_1 = +\sqrt[4]{4 \ / 7} \approx 0.87$.

Если функция F(x) не является алгебраической, то нелинейное уравнение (2.1) называется *трансцендентным*.

Например, к трансцендентным уравнениям могут быть отнесены следующие нелинейные уравнения: $x-10\sin(x)=0$, $2^x-2\cos(x)=0$, $\lg(x+5)=\cos(x)$.

В некоторых частных случаях решение трансцендентных уравнений можно свести к решению им эквивалентных алгебраических уравнений.

Поскольку подавляющее большинство нелинейных уравнений с одной переменной не решаются путем аналитических преобразований (точными методами), на практике их решают только численным образом.

Решить такое уравнение – означает установить: имеет ли оно корни вообще, сколько этих корней, а затем – найти значения корней с требуемой точностью.

Задача численного определения действительных и комплексных корней уравнения (2.1) обычно состоит из двух этапов.

Первый этап – отделение корней, т.е. нахождение достаточно малых окрестностей рассматриваемой области, в которых гарантировано содержится один корень.

Второй этап – уточнение корней, т.е. вычисление абсциссы корня с заданной степенью точности.

В дальнейшем будем рассматривать численные методы нахождения действительных корней уравнения (2.1).

Наиболее распространенными на практике численными методами решения уравнения (2.1) являются: метод половинного деления, метод хорд, метод касательных (метод Ньютона), комбинированный метод, метод простой итерации и т.д.

Выбор того или иного численного метода для решения уравнения (2.1) зависит от искомого количества корней, способа задания исходного приближения к этим корням и от поведения функции F(x) на общем интервале поиска корней.

Кроме того, если функция F(x) задается таблично, то данная задача решается с привлечением интерполяционных многочленов, аппроксимирующих функцию F(x).

Это, в свою очередь, обязывает более взвешенно подходить к вопросу выбора конкретного численного метода решения нелинейного уравнения и к проблеме программной реализации такого алгоритма в целом.

В этом случае итоговая погрешность при определении корня будет зависеть и от порядка точности, обеспечиваемой выбранным интерполяционным многочленом.

Проблема поиска корней комплексной функции может быть заменена процедурой поиска точки на комплексной плоскости, в которой достигает минимума модуль комплексной функции.

Первый этап численного решения уравнения (2.1) состоит в отделении корней, т.е. в установлении достаточно «малых» промежутков из области определения функции F(x), на которых гарантированно содержится только один простой корень.

Отделение корней во многих случаях можно произвести либо графически, либо воспользоваться вычисленной таблицей функции.

Принимая во внимание, что действительные корни уравнения (2.1) – это точки пересечения графика функции F(x) с осью абсцисс, достаточно построить график функции F(x) и отметить на оси Ox отрезки, содержащие по одному корню.

Построение графиков можно существенно упростить, заменив уравнение (2.1) равносильным ему уравнением $f_1(x) = f_2(x)$, как это мы выполнили выше для нелинейного уравнения (2.3).

В этом случае строятся графики функций $f_1(x)$ и $f_2(x)$, а потом на оси Ox отмечаются отрезки, локализирующие абсциссы точек пересечения этих графиков.

В сомнительных случаях графическое отделение корней необходимо подкреплять вычислениями.

При этом полезно использовать следующие очевидные положения:

- если непрерывная на отрезке [a,b] функция F(x) принимает на его концах значения разных знаков, т.е. $F(a) \cdot F(b) < 0$, то уравнение (2.1) имеет на этом отрезке, по меньшей мере, один корень;
- если функция F(x) к тому же еще и строго монотонна (знак первой производной F'(x) не меняется во всех точках на [a,b]), то корень уравнения (2.1) на отрезке [a,b] будет единственным (простой корень).

Итак, пусть имеется уравнение F(x) = 0, причем можно считать, что все интересующие вычислителя корни находятся на некотором заданном отрезке [A,B], на котором функция F(x) определена и непрерывна.

Требуется отделить все корни уравнения F(x) = 0, т.е. указать все «малые» отрезки $[a_i, b_i] \subset [A, B]$, содержащие только по одному корню.

Будем вычислять значения F(x) и F'(x) (если это возможно), начиная с точки x=A, двигаясь вправо с некоторым шагом h.

Как только обнаружится пара соседних значений F(x), имеющих разные знаки, и функция F(x) будет монотонна на этом отрезке, так соответствующие значения аргумента x (предыдущее и последующее) можно считать концами отрезка $[a_i,b_i]$, содержащего корень x_i .

Очевидно, что надежность рассмотренного подхода к отделению корней уравнения зависит как от характера функции F(x), так и от выбранной величины шага h продвижения от абсциссы A к абсциссе B.

Действительно, если при достаточно малом значении h на концах текущего отрезка [x,x+h], функция F(x) и ее производная F'(x) не изменяют своих знаков, естественно ожидать, что уравнение F(x)=0 корней на этом отрезке не имеет.

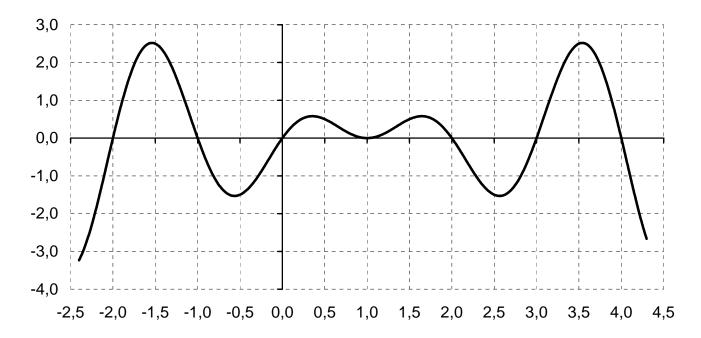
Если же условия монотонности функции F(x) на отрезке [x,x+h] не соблюдаются, т.е. $F'(x)\cdot F'(x+h)<0$, а необходимое условие $F(x)\cdot F(x+h)<0$ не выполнено, то возможно существование двух (или иное четное количество) корней на этом отрезке или имеется корень четной кратности, что проверяется отдельно.

Данная ситуация представлена ниже на графике функции

$$f(x) = (1-x)\sin(\pi x).$$

Так на отрезке [0.5, 1.5] имеем $F(0.5) \cdot F(1.5) > 0$ и $F'(0.5) \cdot F'(1.5) < 0$.

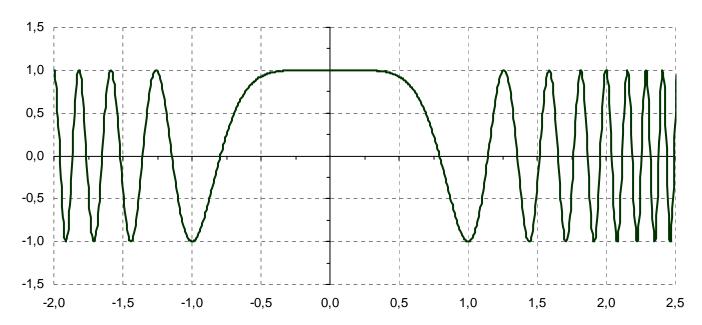
Визуальный анализ показывает, что указанная функция f(x) имеет в точке $x_* = 1$ нуль кратности 2. При этом сам график функции *касается* оси абсцисс Ox в точке с координатой $x_* = 1$.



Остальные нули этой функции, представляющие собой множество целых чисел, очевидно, будут уже простыми корнями данного уравнения $(1-x)\sin(\pi x) = 0$.

При одновременном выполнении условий $F(x) \cdot F(x+h) < 0$ и $F'(x) \cdot F'(x+h) > 0$ на отрезке [x, x+h], последний может содержать как один корень, так и большее (нечетное) их количество.

Такое поведение характерно для сильно осциллирующих функций, например, для функции $f(x) = \cos(\pi x^3)$:



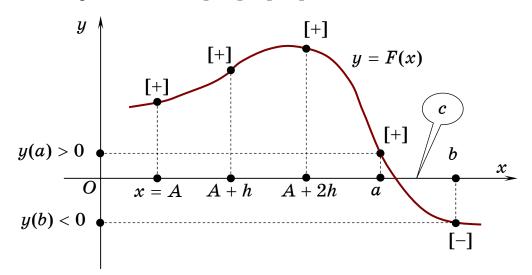
Предвидя подобные случаи, следует выбирать при отделении корней достаточно малые значения шага h, или проводить повторные уточняющие расчеты с шагом $h_1 = h \ / \ 10$ на выделенных (сомнительных) промежутках.

§ 2.2. Метод половинного деления (дихотомии).

Основная идея (алгоритм) метода дихотомии следующая.

Пусть на отрезке [a,b] имеется единственный корень уравнения F(x)=0.

Разделим этот отрезок пополам $[a,c] \cup [c,b]$ точкой c = (a+b)/2.



Если $F(c) \neq 0$ (что практически наиболее вероятно), то возможны два случая: либо F(x) меняет знак на первом отрезке $[a,c] \in [a,b]$, либо смена знака F(x) происходит на втором отрезке $[c,b] \in [a,b]$.

Выбирая в каждом случае тот из отрезков, на котором функция меняет знак, и, продолжая процесс половинного деления дальше, приходим к сколь угодно малому отрезку, содержащему корень уравнения F(x) = 0.

Следовательно, итерационный процесс метода дихотомии можно представить в виде следующего цикла вычислений, где k – порядковый номер итерации.

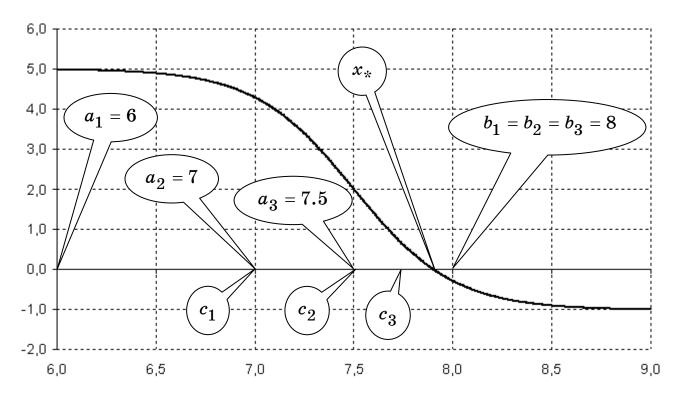
Пусть уже выделен отрезок $[a_k, b_k]$, на концах которого функция F(x) имеет противоположные знаки и, следовательно, который содержит искомый корень x_* .

Определяем середину $c_k = (a_k + b_k) \, / \, 2$ отрезка $[a_k, b_k]$ по алгоритму (1.4) и вычисляем значение $F(c_k)$.

При невыполнении условия $|F(c_k)| < \varepsilon$ итерации продолжаются по правилу:

если
$$F(a_k)\cdot F(c_k)>0\,,$$
 $\left\{egin{array}{ll} & \mbox{ то} & a_{k+1}=c_k\ \mbox{и}\ b_{k+1}=b_k\,, \\ & \mbox{ иначе} & a_{k+1}=a_k\ \mbox{и}\ b_{k+1}=c_k\,, \end{array}
ight.$

т.е. строится новый отрезок $[a_{k+1},b_{k+1}]$ с искомым корнем x_* .



На рисунке представлен итерационный процесс (первые три итерации) для уравнения $2-3 ext{ th}(2x-15)=0$, когда в качестве начального отрезка, содержащего простой корень был выбран $[a_1,b_1]=[6,8]$.

Поскольку искомый корень x_* здесь расположен близко к значению $b_1=8$, за первые три итерации «меняла» положение только левая граница интервала — a_k , а правая граница b_k — оставалась неизменной.

Данный метод является типично компьютерным, надежным и простым в реализации, хотя и обладает при этом медленной сходимостью.

Количество итераций K, необходимых для достижения заданной точности ε , можно оценить из соотношения $K > \log_2((b-a)/\varepsilon)$.

Алгоритм деления отрезка пополам, базирующийся на формуле (1.3-б), следует применять в программах, которые могут быть потенциально использованы для вычисления корней с максимально возможной точностью.

Кроме того, на процессорах, в которых вместо округления осуществляется отбрасывание лишних разрядов, формула (1.3-а) может вообще вывести за пределы текущего подотрезка.

Лучше придерживаться следующего правила, согласно которому новое приближение следует вычислять прибавлением полученной поправки к текущему приближению.

Положительная величина ε , задаваемая изначально, не должна быть меньше абсолютной погрешности вычисления самой функции F(x) на интервале [a,b].

Кроме этого, задаваемая точность ε должна выбираться в соответствии с количеством значащих цифр мантиссы чисел с плавающей запятой, использованных и соответствующим образом описанных в конкретной программе.

Если же на некотором шаге итераций имеет место $(b_k - a_k) < \varepsilon$, а условие $|F(c_k)| < \varepsilon$ не выполняется, то возможно зацикливание программы и расчеты необходимо принудительно завершать.

При этом итоговая погрешность вычислений, допущенная при определении корня, будет иметь величину $\epsilon_1 = \left| F(c_k) \right|$, причем $\epsilon_1 > \epsilon$.

Выхол ИЗ указанной ситуации лишь возможен алгебраического путем преобразования уравнения F(x) = 0к какому-либо эквивалентному уравнению G(x) = 0 с последующим построением алгоритма повышенной точности ДЛЯ вычисления значений функции G(x).

Метод дихотомии удобен при решении уравнений, для которых неизвестен аналитический вид функции F(x).

Например, поиск отдельного собственного значения λ действительной матрицы $A[n \times n]$ можно производить метом половинного деления, минуя стадию составления характеристического уравнения $f(\lambda) = 0$.

Для этого (при помощи соответствующих численных процедур) решается задача $\det(A - \lambda E) = 0$, где E - единичная матрица.

§ 2.3. Метод Ньютона (касательных).

Рассматриваемый метод базируется на теореме Больцано-Коши:

Eсли $F(x) \in C_2[a,b]$ и $F(a) \cdot F(b) < 0$, т.е. F(x) принимает на концах отрезка [a,b] значения с противоположными знаками, а F'(x) не меняет знака на [a,b], то уравнение F(x) = 0 имеет на [a,b] единственное решение (корень) x_* .

Существование решения $x_* \in [a,b]$ следует из непрерывности F(x) на [a,b] и предположения $F(a) \cdot F(b) < 0$. Не единственность решения при условии $F(a) \cdot F(b) < 0$ повлекла бы изменение знака у F'(x) на [a,b].

Метод Ньютона, называемый также методом касательных, состоит в следующем.

Рассмотрим в точке $x^{(0)}$ касательную к кривой f = F(x), задаваемую уравнением $y_1(x) = F(x^{(0)}) + (x - x^{(0)}) \cdot F'(x^{(0)})$.

Положив $y_1 = 0$, определяем точку $x^{(1)}$ пересечения данной касательной $y_1(x)$ с осью абсцисс Ox:

$$x^{(1)} = x^{(0)} - \frac{F(x^{(0)})}{F'(x^{(0)})}. (2.4)$$

Строим новую касательную $y_2(x) = F(x^{(1)}) + (x - x^{(1)}) \cdot F'(x^{(1)})$ к графику функции f = F(x) в только что найденной точке $x^{(1)}$.

Эта прямая также пересекает ось абсцисс Ox.

Решаем новое линейное уравнение $y_2(x) = 0$ и получаем точку пересечения второй касательной с осью Ox:

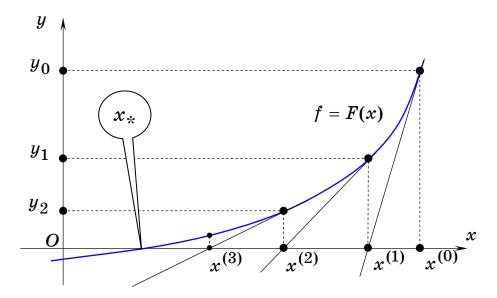
$$x^{(2)} = x^{(1)} - \frac{F(x^{(1)})}{F'(x^{(1)})}$$
.

Очевидна итерационная последовательность данного численного метода:

$$y_k(x) = F(x^{(k)}) + (x - x^{(k)}) \cdot F'(x^{(k)}), \Rightarrow$$

$$y_k(x^{(k+1)}) = 0 \implies x^{(k+1)} = x^{(k)} - \frac{F(x^{(k)})}{F'(x^{(k)})}.$$
 (2.5)

Из геометрических соображений ясно, что при условиях сформулированной выше теоремы, итерационная последовательность $\{x^{(k)}\}$ по формуле (2.5), монотонно сходится к искомому решению x_* уравнения F(x) = 0, см. рисунок на следующей странице.

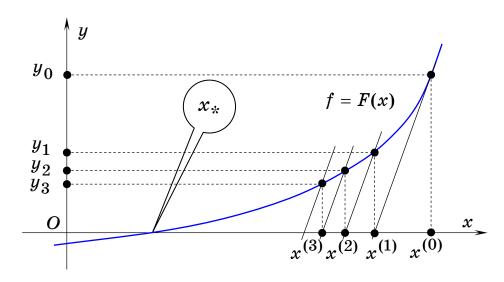


Итерации по схеме (2.5) для трансцендентных уравнений имеют наибольшую скорость сходимости среди известных численных методов.

Для простоты алгоритма иногда используют модифицированный метод Ньютона:

$$x^{(k+1)} = x^{(k)} - \frac{F(x^{(k)})}{F'(x^{(0)})}, \qquad (2.6)$$

где упрощение состоит в том, что значение производной $F'(x^{(0)})$ (тангенс угла наклона касательной к графику функции) вычисляется один раз в начальной точке $x^{(0)}$.



Это, конечно, снижает скорость сходимости данного итерационного процесса, но никак не сказывается на его итоговой точности.

Очевидно, что пользоваться указанными итерационными методами (2.5)–(2.6) можно лишь в том случае, когда задан аналитический вид функции F(x) и нет проблем с вычислением ее производных F'(x) и F''(x).

Определяющим моментом при реализации вычислений по данному методу является задание начального приближения $x^{(0)}$ к искомому корню x_* .

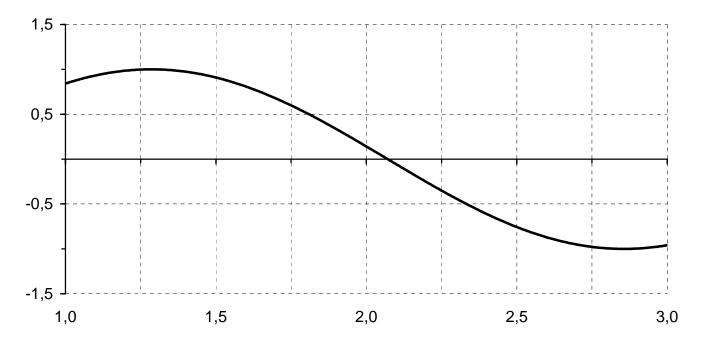
Поэтому, при выборе начального значения $x^{(0)}$ рекомендовано руководствоваться следующим дополнительным условием:

$$F(x^{(0)}) \cdot F''(x^{(0)}) > 0.$$
 (2.7)

Указанное условие не может быть использовано тогда, когда нуль функции F(x) одновременно является нулем и для второй производной F''(x).

В таком случае точка перегиба на графике функции совпадет с точкой пересечения графика функции и оси Ox.

Например, это будет для уравнения $F(x) = \sin(2x - 1) = 0$.



Очевидно, что в данном случае $F''(x) = -4\sin(2x-1) = -4 \cdot F(x)$, и тогда для любого значения переменной $x \in (-\infty, +\infty)$ будем иметь $F(x) \cdot F''(x) \le 0$.

Подводя итог сказанному, сформулируем основные положения метода касательных: если $F(a) \cdot F(b) < 0$, причем F'(x) и F''(x) отличны от нуля и сохраняют свои знаки на [a,b], то при выборе начального приближения $x^{(0)}$ с учетом условия (2.7), итерационный процесс (2.5) всегда сходится к точному значению корня x_* .

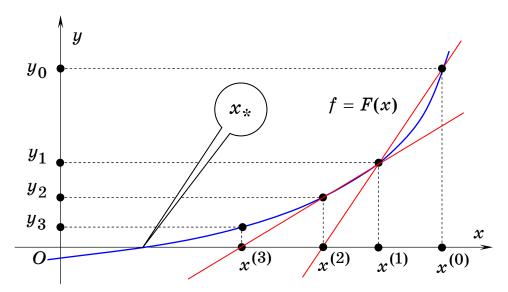
§ 2.4. Метод секущих (метод хорд).

Как уже отмечалось выше, в методе Ньютона необходимо вычислять производную F'(x), что не всегда представляется возможным. Если заменить эту производную разделенной разностью первого порядка, вычисленной на двух последних итерациях:

$$F'(x^{(k)}) \approx \Delta F(x^{(k-1)}, x^{(k)}) = \frac{F(x^{(k)}) - F(x^{(k-1)})}{x^{(k)} - x^{(k-1)}},$$
(2.8)

то из (2.5) можно получить итерационную формулу обобщенного метода хорд (секущих):

$$x^{(k+1)} = x^{(k)} - \frac{x^{(k)} - x^{(k-1)}}{F(x^{(k)}) - F(x^{(k-1)})} \cdot F(x^{(k)}), \quad k = 1, 2, \dots$$
 (2.9)



Геометрическая интерпретация классического метода хорд следующая: через две точки $(x^{(k-1)}, F(x^{(k-1)}))$ и $(x^{(k)}, F(x^{(k)}))$ кривой f = F(x) проводится секущая, пересекающая ось абсцисс Ox в точке $x^{(k+1)}$.

Из узлов $x^{(k-1)}$ и $x^{(k)}$ отбрасывается тот, для которого значение функции F(x) имеет тот же знак, что и значение $F(x^{(k+1)})$, или тот, для которого значение функции имеет большую величину (по модулю), после чего итерации (2.8) продолжаются.

В том случае, когда искомый корень x_* уже заключен в границах известного нам подотрезка [a,b], поскольку для него производилась предварительная проверка на выполнение условия $F(a) \cdot F(b) < 0$, итерации по методу секущих можно упростить.

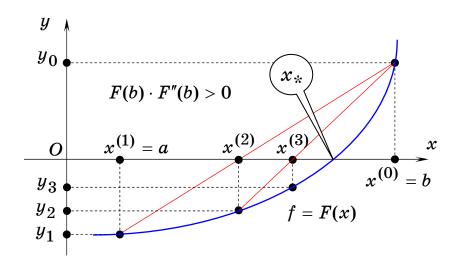
Очевидно, что если в качестве узлов $x^{(0)}$ и $x^{(1)}$ выбрать концы подотрезка [a,b], т.е. взять, например, $x^{(0)} = a$ и $x^{(1)} = b$, то в процессе итераций (2.9) один из них не будет менять своего «положения».

Условимся, что в качестве $x^{(0)}$ мы будем выбирать тот из концов подотрезка [a,b], для которого выполняется условие вида (2.7), т.е. $F(x^{(0)}) \cdot F''(x^{(0)}) > 0$.

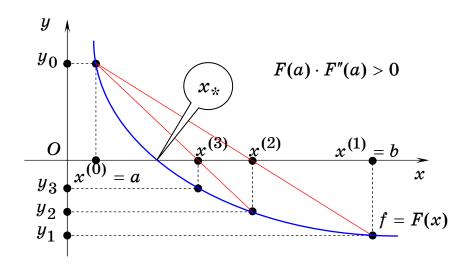
Таким образом, зафиксировав концевую точку $x^{(0)}$ подотрезка [a,b], для которой выполняется условие $F(x^{(0)}) \cdot F''(x^{(0)}) > 0$, из (2.9) получим традиционную схему метода хорд (секущих):

$$x^{(k+1)} = x^{(k)} - \frac{x^{(k)} - x^{(0)}}{F(x^{(k)}) - F(x^{(0)})} \cdot F(x^{(k)}), \quad k = 1, 2, \dots$$
 (2.10)

Ниже представлена геометрическая интерпретация метода хорд по схеме (2.10), когда в качестве $x^{(0)}$ оказывается выбранной правая граница подотрезка [a,b]:



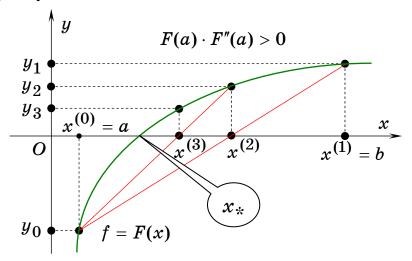
Альтернативная ситуация выглядит так:



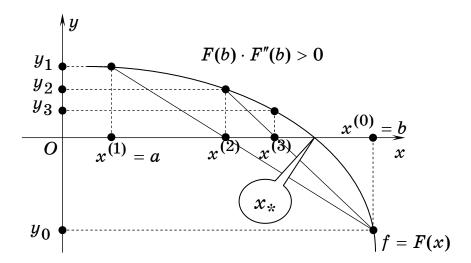
В рассмотренных выше двух случаях вторая производная F''(x) функции F(x) была положительной, т.е. F''(x) > 0 на [a,b].

График функции F(x) при этом на интервале [a,b] имел вогнутость «вниз».

В тех случаях, когда F''(x) < 0 на интервале [a,b] (т.е. график функции имеет вогнутость «*вверх*»), очевидно, возможны еще две геометрические интерпретации хода итераций по методу секущих:



ИЛИ



Сложность с выбором $x^{(0)}$ может возникнуть, если на сегменте [a,b] меняет знак вторая производная. Такое уравнение мы уже рассматривали выше — уравнение $\sin(2x-1)=0$. В данном случае всегда имеет место $F(x)\cdot F''(x)\leq 0$.

Или может оказаться, что всегда $F(x) \cdot F''(x) \ge 0$, например, для алгебраического (нелинейного) уравнения $F(x) = (x-1)^3 = 0$.

Метод касательных или метод секущих может не обеспечить сходимости для корня уравнения такого типа.

В таких случаях следует воспользоваться методом дихотомии для уточнения корня.

Для определения кратных нулей нелинейного уравнения можно воспользоваться каким-либо приближенным (численным) методом поиска точек минимума для функции $\Phi(x) = |F(x)|$. Очевидно, что если в некоторой точке $\tilde{x} \in [a,b]$ функция $F(\tilde{x}) = 0$, то функция $\Phi(x)$ имеет в этой точке минимум, притом равный нулю, т.е. $\Phi(\tilde{x}) = 0$.